



**Budapesti Műszaki és Gazdaságtudományi Egyetem**  
Villamosmérnöki és Informatikai Kar  
Mesterséges Intelligencia és Rendszertervezés  
Tanszék

Frey Bence

**MESTERSÉGES INTELLIGENCIA  
ALKALMAZÁSA AGYSZÖVETBE  
ÜLTETETT ELEKTRÓDÁKBÓL  
SZÁRMAZÓ JELEK  
FELDOLGOZÁSÁRA**

BELSŐ KONZULENS

**Dr. Szlávecz Ákos**

KÜLSŐ KONZULENS

**Dr. Rokai János**

BUDAPEST, 2026

# Tartalomjegyzék

|                                                                     |           |
|---------------------------------------------------------------------|-----------|
| <b>Összefoglaló .....</b>                                           | <b>4</b>  |
| <b>Abstract.....</b>                                                | <b>5</b>  |
| <b>1 Bevezetés .....</b>                                            | <b>6</b>  |
| <b>2 Irodalmi áttekintés.....</b>                                   | <b>7</b>  |
| 2.1 Tüske-rendezés .....                                            | 7         |
| 2.1.1 Kihívások.....                                                | 7         |
| 2.1.2 Hagyományos módszerek.....                                    | 7         |
| 2.1.3 Mélytanuláson alapuló módszerek.....                          | 9         |
| 2.2 Tüske-előrejelzés .....                                         | 9         |
| 2.2.1 Mélytanuláson alapuló módszerek.....                          | 10        |
| <b>3 Felhasznált adatkészletek.....</b>                             | <b>12</b> |
| 3.1 Kísérleti paradigma és feladatstruktúra .....                   | 12        |
| 3.1.1 Neurológiai felvételek: Elektrofiziológia és tüskeadatok..... | 13        |
| 3.1.2 Viselkedési adatok: Kerékmozgások és döntési kimenetek .....  | 14        |
| <b>4 Módszertan .....</b>                                           | <b>15</b> |
| 4.1 Vizuális inger feldolgozása.....                                | 16        |
| 4.1.1 CLIP vizuális kódoló .....                                    | 16        |
| 4.2 Neurális jelek feldolgozása .....                               | 16        |
| 4.2.1 Neurális kódoló.....                                          | 17        |
| 4.3 Tokenizálás és beágyazás leképezés.....                         | 17        |
| 4.3.1 Vizuális tokenek generálása.....                              | 17        |
| 4.3.2 Neurális tokenek generálása .....                             | 17        |
| 4.4 Multimodalitás .....                                            | 17        |
| 4.4.1 Pozicionálási beágyazások.....                                | 18        |
| 4.4.2 Modalitás beágyazások .....                                   | 18        |
| 4.4.3 Munkamenet beágyazások.....                                   | 18        |
| 4.5 Transformer-alapú szekvencia modellezés .....                   | 18        |
| 4.6 Maszkolási stratégia és önfelügyelt tanulás.....                | 19        |
| 4.6.1 Keresztmodális igazítás .....                                 | 19        |
| 4.7 Veszteségfüggvények és optimalizálás.....                       | 19        |
| 4.8 Betanítási stratégia .....                                      | 20        |

|                             |           |
|-----------------------------|-----------|
| <b>5 Kiértékelés .....</b>  | <b>21</b> |
| 5.1 Kiértékelés menete..... | 21        |
| 5.2 Eredmények .....        | 22        |
| <b>6 Célkitűzések.....</b>  | <b>23</b> |
| <b>Irodalomjegyzék.....</b> | <b>24</b> |

# Összefoglaló

A nagy sűrűségű elektrofiziológiai rögzítési technológiák fejlődése lehetővé tette több száz neuron idegi aktivitásának egyidejű mérését több agyi régióban. Ezek a fejlesztések új lehetőségeket, annak megértéséhez, hogy az idegi populációdinamika hogyan vezet viselkedéshez. Különösen az agyba beültetett elektródákról rögzített jelek elemzése igényel robusztus számítási módszereket az egyes neuronális jelek elkülönítéséhez és a prediktív információk kinyeréséhez időbeli szerkezetükből. A mesterséges intelligencia, és különösen a mélytanulás, hatékony eszközzé vált a kihívások kezelésében.

Ez a munka a mélytanuláson alapuló módszerek alkalmazását vizsgálja beültetett elektródákkal rögzített idegi jelekre, különös tekintettel a tüske-rendezésre és a tüske-előrejelzésre. A munka részletezi az IBL adatbázist, melynek adatait felhasználva egy olyan mélytanuló hálót tervez és értékel, amely képes, felfedezni az agy vizuális feldolgozás és döntéshozatali folyamatainak közötti bonyolult kapcsolatra és ez alapján képes megjósolni az egér vizuális ingerre adott döntését.

# **Abstract**

The development of high-density electrophysiological recording technologies has enabled the simultaneous measurement of neural activity from hundreds of neurons in multiple brain regions. These developments have opened up new possibilities for understanding how neural population dynamics drive behavior. In particular, the analysis of signals recorded from electrodes implanted in the brain requires robust computational methods to isolate individual neuronal signals and extract predictive information from their temporal structure. Artificial intelligence, and in particular deep learning, has become an effective tool in addressing these challenges.

This work investigates the application of deep learning-based methods to neural signals recorded from implanted electrodes, with a particular focus on spike sorting and spike prediction. The work details the IBL database, using which data is used to design and evaluate a deep learning network that is able to discover the complex relationship between the brain's visual processing and decision-making processes and, based on this, is able to predict the decision of a mouse to a visual stimulus.

# 1 Bevezetés

A modern idegtudomány egyik központi kihívása annak megértése, hogy az idegi aktivitás hogyan idézi elő a viselkedést. A legújabb technológiai fejlesztések (nevezetesen a nagy sűrűségű szilíciumszondák, mint például a Neuropixels) lehetővé teszik a kutatók számára, hogy több száz neuronról milliszekundumos pontossággal rögzítsenek adatokat több agyi régióban egyszerre. Ezek az eszközök lehetővé tették nagyméretű adatkészletek létrehozását, amelyek nagy felbontással rögzítik az érzékszervi feldolgozást, a döntéshozatalt és a motoros felkészülést.

Az ilyen felvételekből értelmes struktúra kinyerése fejlett számítási módszereket igényel, amelyek képesek nagydimenziós, zajos és nem stacionárius neurális adatok kezelésére. Ennek a folyamatnak az alapvető lépése a tüske-rendezés, amely az extracelluláris feszültséggörbéket az egyes neuronokhoz rendelt akciós potenciálokká bontja le. A modern tüske-rendezési megközelítések egyre inkább automatizált klaszterezési algoritmusokat és mély neurális hálózatokat alkalmaznak a skálázhatóság és a konzisztencia javítása érdekében. A tüske-sorozatok birtokában, a kutatók célja annak megértése, hogy az idegi aktivitás hogyan fejlődik az idő múlásával, és hogy felhasználható-e a jövőbeni idegi vagy viselkedési események előrejelzésére.

Ezen munka célja, hogy ezeket a neurális felvételeket felhasználva mélytanuló modellt hozzon létre, amely a korábbi neurális aktivitás alapján előrejelzi a kerékmozgás viselkedését. E célkitűzés támogatása érdekében ezen munka először áttekinti a modern számítási módszereket a tüske-rendezéshez és a tüske-előrejelzéshez, a klasszikus jellemzőalapú algoritmusokról a kortárs mélytanuló architektúrákra való áttérésre összpontosítva. Végül a munka egy olyan neurális hálózati modellt javasol és értékel, amely az előfeldolgozott tüske-rendezés eredményeit felhasználva megjósolja az egér következő viselkedési döntését.

A rendszerneurotudomány, az elektrofiziológia és a gépi tanulás koncepcióinak integrálásával a munka célja, hogy hozzájáruljon az elosztott neurális populációdinamikából származó komplex viselkedések szélesebb körű megértéséhez.

## **2 Irodalmi áttekintés**

### **2.1 Tüske-rendezés**

A modern idegtudományban használatos több száz vagy akár több ezer csatornás extracelluláris elektródák a neuronok elektromos impulzusainak rögzítésére alkalmasak. Az elektródák által rögzített jel nem csak egy neuron akciós potenciálját tartalmazza, hanem az elektróda környezetében lévő több neuron akciós potenciáljaiból áll. A tüske-rendezés az a folyamat, amely lehetővé teszi, hogy ezt a jelet egyetlen neuron aktivitására bontsuk szét [1][2][3].

#### **2.1.1 Kihívások**

Az extracelluláris felvételek eredendően zajosak: a neurális tüskék mellett a feszültségörbék háttér elektromos aktivitást, hőzajt, mozgásból származó zavarjelek és nem neurális potenciálokat is tartalmaznak. A valódi tüskék és a zaj megkülönböztetése bonyolítja mind az észlelést, mind a későbbi klaszterezést. Ezek torzíthatják a hullámforma alakját és ronthatják az osztályozási teljesítményt [2].

A különböző neuronokból származó aktivitások hasonló alakúak lehetnek, vagy nagyon közel egymáshoz fordulhatnak elő, ami olyan átfedést okozhat, amelyet a hagyományos detektorok nem tudnak jól elkülöníteni [1].

A több csatornás felvételek növelik a dimenzionalitást és a variabilitást. A hullámformák alakja változhat a neuronok és a rögzítési körülmények között, ezért az egyszerű jellemzőterek nem jól általánosíthatóak [2].

#### **2.1.2 Hagományos módszerek**


A hagyományos tüske-rendezés egy többlépcsős folyamat, amely előfeldolgozásból, tüske-észlelésből, hullámforma-kinyerésből és -illesztésből, jellemző-kinyerésből, klaszterezésből, sablonfinomításból, manuális kurációból és minőségértékelésből áll. Minden lépés hozzájárul az egységesebb aktivitás elkülönítéséhez az extracelluláris keverékektől, de mindegyik hibalehetőségeket is teremt, különösen zaj, hullámforma-változékonyság, átfedő tüskék és elektróda-driftus jelenlétében. Ezek a kihívások ösztönözték a modern mélytanulási megközelítések

fejlesztését, amelyek ezen lépések közül többet egységes keretrendszerekbe integrálnak, csökkentett manuális beavatkozással.

A hagyományos tüske-rendezés több lépésre oszlik melyek:

- A nyers EEG jel előfeldolgozása: Sávszűrő segítségével elkülönítik azt a frekvenciatartományt, ahol az akciós potenciálok dominálnak.
- Tüske felismerés: Vagy küszöbérték számítás vagy detektor algoritmusok használatával.
- Hullámforma-kivonás: Javítja a Neuropixels osztályú szondák pontosságát.
- Tüskék amplitúdócsúchoz illesztése: Célja, hogy csökkentse a mesterséges varianciát és javítsa a jellemzők kiszámítását és a klaszterezés stabilitását.
- Tulajdonság kinyerése: Célja a dimenziók csökkentése.
- Klaszterizáció: Hasonlóság alapján csoportosítja a tüskéket egységekbe.

Az első lépésben a neuron aktivitásokat kerülnek elkülönítésre a nyers adatsorból. Ezt követően megtörténik a tüskék detektálása és azok amplitúdó csúchoz illesztése. A következő lépésben a dimenziók csökkentése érdekében a tulajdonságok kinyerése és végül a csoportosítás [1].



**1. ábra** Hagyományos felügyelet nélküli tüske-rendezés folyamatábrája. (a) Négy elektróda rögzíti az elektródához közeli három neuron elektromos aktivitásának változásait. A nyers adatokat (b) jellemzően egy sáváteresztő szűrővel (c) dolgozzák fel, amely lehetővé teszi a tüskék detektálását (d). Ezt követően a tüskéket igazítják (e) a jellemzők kinyeréséhez (f). Az osztályozás alkalmazható az alacsony szintű jellemzőtérben a tüskés események csoportosítására (g), ahol egy osztály átlagát sablonnak (h) nevezik. Végül a tüske-sorozatokat rekonstruálhatók a megfelelő tüske-idővel (i) [1].

### 2.1.3 Mélytanuláson alapuló módszerek

Az elmúlt években a tüske-rendezés jelentős fejlődésen ment keresztül. A hagyományos mellett egyre nagyobb teret hódítanak a mélytanuláson alapuló módszerek. Ennek háttérében elsősorban az áll, hogy a modern extracelluláris felvételek nagy mennyiségű, nagy dimenziós adatot generálnak, melyeknél a hagyományos módszerek nem biztos, hogy optimális. A mélytanuláson alapuló módszerek a ugyanazokat a fő lépéseket valósítják meg, mint a hagyományos módszerek azzal a különbséggel, hogy egy vagy több lépésben a korábban alkalmazott klasszikus algoritmusokat (például klasztericáció esetében k-means algoritmus) egy mélytanuláson alapuló modell váltotta fel [1].

1. táblázat A mélytanulási modell típusok felhasználása és jelentősége

| Mélytanulási modell típus | Felhasználása                            | Jelentősége                                                                                              |
|---------------------------|------------------------------------------|----------------------------------------------------------------------------------------------------------|
|                           |                                          |                                                                                                          |
| CNN                       | Detektálás, jellemzőkivonás, osztályozás | Több csatornát egyszerre kezel, felismeri a szomszédos elektródákon megjelenő hullámforma-terjedést [4]. |
| Autoencoder (AE)          | Jellemzőkivonás                          | Képes a csatornák közti korrelációt megtanulni [4].                                                      |
| Recurrent NN (RNN)        | Drift-korrekció, időbeli mintázatok      | Több csatornás idősorokon képes kiszűrni a hosszú távú hullámforma-eltolódást [1].                       |

## 2.2 Tüske-előrejelzés

A tüske-előrejelzés a jövőbeli neurális tüzelési események előrejelzésére szolgál a múltbeli idegi aktivitás, külső bemenetek vagy viselkedési állapotok alapján. A klinikai és számítógépes idegtudományban a tüske-előrejelzést gyakran az agyi állapotok főbb átmeneteinek előrejelzése például az epilepsziás rohamot megelőző tüskék gyors növekedése, vagy a tüzelési minták változásai, amelyek egy közelgő mozgást előre jeleznek. Az időbeli minták, spektrális eltolódások, konnektivitás változások vagy tüskesebesség-ingadozások azonosítását foglalja magában, amelyek a preiktális

időszakban jelentkeznek. Ezek az esemény előtti idegi jellemzők lehetnek finomak, nem lineárisak és alanyspecifikusak, ezért a klasszikus modellekről, a mélytanulási megközelítések kerültek előtérbe, amelyek komplex téridőbeli dinamikát tudnak modellezni [5][6][7].

### 2.2.1 Mélytanuláson alapuló módszerek


A mélytanulás átalakította a tüskék előrejelzésének tájképét azáltal, hogy lehetővé tette a modellek számára, hogy rögzítsék a nagyléptékű neurális állapotátmeneteket megelőző komplex téridőbeli mintázatokat. Míg a teljes predikciós folyamatok gyakran több szakaszt tartalmaznak például tüskék detektálását, morfológiai elemzését, csatornaválasztást vagy jellemzőkinyerést, a jelenlegi munka kizárólag ezen rendszerek predikciós fázisára összpontosít. Minden esetben a mélytanuló prediktor olyan neurális adatokat kap, amelyek már átestek a szükséges előfeldolgozáson, és felelős a jövőbeli eseményeket előrejelző időbeli és térbeli mintázatok tanulásaért.

A konvolúciós neurális hálózatok (CNN-ek) az egyik legkorábbi mélytanulási megközelítés a tüske-előrejelzés terén. A Jincan Zhang és munkatársai tanulmányban a hálózatot úgy tervezték, hogy közvetlenül a nyers EEG-bemenetből vonjon ki diszkriminatív időbeli jellemzőket, lehetővé téve a rendszer számára, hogy korai preiktális szignatúrákat detektáljon a jellemzőkivonás vagy explicit tüske-észlelési lépések nélkül [5]. A modell rövid EEG-ablakokat dolgoz fel, és automatikusan felfedezi a közeledő iktális eseményekhez kapcsolódó lokális téridőbeli jeleket, beleértve az alacsony frekvenciájú felhalmozódást, az átmeneti nagyfrekvenciás kisüléseket és a finom nemlineáris torzításokat. Hasonlóképpen, a DTS-GAN-t bemutató 2025-ös Scientific Reports cikkben a CNN-eket idő-frekvencia bemenetekre alkalmazzák a preiktális és interiktális ablakok robusztus osztályozása érdekében [7].

A rekurrens neurális hálózatok, különösen a hosszú rövid távú memória (LSTM) architektúrák, kiterjesztik a CNN-ek kapacitását a hosszú távú időbeli függőségek modellezésével. Az Kostas M. Tsiouris és munkatársai kimutatták, hogy ezek a modellek felülmúlják a klasszikus gépi tanulási megközelítéseket, mivel képesek integrálni az idegi aktivitás kiterjesztett előzményeit és detektálni a lassan fejlődő preiktális átmeneteket [5]. Ebben a munkában az LSTM bemenetként nyers EEG-szegmenseket, spektrális jellemzők szekvenciáit vagy korábbi feldolgozási lépésekből származó időbeli leírókat kap. Egy másik modell, amely a CNN és az LSTM modulokat kombinálja, megerősíti ezt

a megközelítést: a térben lokalizált jellemzők konvolúciós rétegekkel történő első kinyerésével, majd az időbeli evolúció rekurrens rétegekkel történő modellezésével a hálózat kiváló érzékenységet ér el a preiktális szignatúrák azonosításában [6].

A figyelemalapú mélymodellek dinamikusan súlyozzák a csatornákat, időpontokat vagy frekvenciakomponenseket, lehetővé téve a modell számára, hogy adaptívan kiemelve azokat az információkat, amelyek az esemény kezdete előtt relevánssá válnak. A Jincan Zhang és munkatársai figyelemmechanizmusokat mutatnak be a CNN jellemzőinek finomítására és az EEG-jel kritikus részeinek felerősítésére [6].




**2. ábra** A CNN-GRU-ANN architektúra modellje epilepsziás rohamok előrejelzésére és detektálására [6].

### **3 Felhasznált adatkészletek**

A Nemzetközi Agylaboratórium (IBL) adatkészlete az egerek vizuálisan vezérelt döntéshozatalának neurális alapjainak feltárására tervezett adatkészlet több agyterületről származó egyidejű neurális felvételeket tartalmaz, valamint az hozó tartozó viselkedési méréseket. A rohamelőrejelzési vizsgálatokkal ellentétben, amelyek az EEG kóros átmeneteire összpontosítanak, az IBL adatkészlet egészséges, feladatvezérelt neurális dinamikát rögzít. Ezen munka céljaira az IBL adatkészlet szolgál alapul olyan mélytanulási modellek fejlesztéséhez, amelyek képesek az idegi aktivitásból megjósolni a közelgő kerékmozgási viselkedést [8].

#### **3.1 Kísérleti paradigma és feladatstruktúra**


Az IBL vizuális döntéshozatali feladatban a fejhez rögzített egereket arra képezik ki, hogy a kormánykereket manipulálva jelezzék a vizuális inger érzékelt helyét. Egy nagy kontrasztú rács jelenik meg a monitor bal vagy jobb oldalán, amelynek előzetes valószínűsége a blokkokonként váltakozik. Az egér a kerék érzékelt inger felé forgatásával jelzi választását, és a helyes válaszokért jutalmat kap [8]. A kerékmozgás viselkedését nagy időbeli felbontással rögzítik, az inger és az eredmény eseményeket pedig pontosan rögzítik, ami lehetővé teszi a viselkedési események és az idegi aktivitás közötti szoros összehangolást [9].



3. ábra Az IBL feladat vázlata és egy példa munkamenet blokkstruktúrája [10].

### 3.1.1 Neurológiai felvételek: Elektrofiziológia és túskeadatok

Az IBL adatkészlet elektrofiziológiai komponensét elsősorban Neuropixel próbákkal nyerik, amelyek több száz helyről rögzítenek egyszerre, kérgi és kéreg alatti régiókban. A publikált agyszintű térkép több mint 621 000 neuront mutat be, amelyeket 699 Neuropixel próbával rögzítettek 139 egéren 12 laboratóriumban. Ezek a próbák nagy térbeli felbontást és nagy időbeli felbontást (jellemzően 30 kHz-es minta) biztosítanak, lehetővé téve az idegi dinamika közel egyidejű megfigyelését számos, az érzékelésben, a döntéshozatalban és a mozgásban résztvevő régióban [9].




4. ábra Neuropixel-szonda pályák 3D-s agyi vázlaton. Összesen 699 beillesztést végeztek 139 egéren. **b**, Minden régió esetében látható a rögzített neuronok száma (teljes oszlophossz) és az elemzéshez felhasznált jól izolált neuronok száma (kitöltött rész; referenciaiként az egyes oszlopokon lévő fekete vonal a rögzített neuronok számának 10%-át mutatja, ami a jól izolált neuronok átlagos száma) [10].

### 3.1.2 Viselkedési adatok: Kerékmovások és döntési kimenetek

Az IBL adatkészlet tartalmazza a kormánykerék folytonos méréséből származó nagy felbontású pozíció- és sebességgörbéket, illetve további eseményjelzőket, mint az inger kezdete, az indulási jelzés, a kerékmovás kezdete, a választott irány (bal vagy jobb) és a jutalom átadása [9].

## 4 Módszertan

Ez a jelen munka egy multimodális, transzformátor-alapú keretrendszert javasol a IBL adatkészletében rögzített vizuális ingerekből származó neurális reprezentációk előrejelzésére. A rendszer célja a vizuális információk és az egér vizuális kérgébe beültetett elektródákról mért neurális aktivitás közötti közös látens reprezentáció megismerése. A keretrendszer integrálja a számítógépes látás kódolókat, a neurális jel tokenizációt, a transzformátor-alapú szekvenciamodellezést, a maszkolási stratégiákat és a több munkamenetes adaptációs technikákat.



5. ábra Multimodális transzformátor -folyamat vizuális ingerekből származó neurális reprezentációk előrejelzésére

A rendszer szinkronizált vizuális ingereket és neurális felvételeket fogad bemenetként. A rendszer vizuális ingereket videó formátumban CLIP látáskódolóval kódolja, míg az idegi aktivitást temporális neurális tokenekké alakítja. Mindkét modalitást egy közös beágyazási térbe kerül kivetítésre, és együttesen kerülnek feldolgozásra egy transzformátor kódoló architektúra segítségével. A modellt több célkitűzéssel kerül betanításra, beleértve a neurális látens predikciót, a CLIP beágyazási rekonstrukciót, a maszkolt modellezést és a keresztmodális igazítást.

## 4.1 Vizuális inger feldolgozása

A vizuális ingereket a kísérleti felvételekből kinyert videóképkockák időbeli szekvenciáiként ábrázoljuk. Minden képkocka egy diszkrét időlépésnek felel meg, amely az idegi aktivitási cellákhoz van igazítva, melynek segítségével a modell képes megtanulni a megfigyelt vizuális események és a megfelelő idegi válaszok közötti megfeleltetést.

A magas szintű vizuális reprezentációk kinyeréséhez a modell a CLIP ViT-L/14 vizuális kódolót használja. A CLIP (Contrastive Language–Image Pretraining) egy nagyléptékű vizuális nyelvi modell, amelyet kép-szöveg párokon kontrasztív tanulással tanítottak be. A CLIP kódoló minden bemeneti képkockát sűrű jellemzőbeágyazássá alakít át:

$$x_v \in \mathbb{R}^{D_v}$$

ahol  $x_v$  a vizuális jellemző reprezentációját,  $D_v$  a vizuális beágyazási tér dimenzióját jelöli.

A CLIP beágyazások használata lehetővé teszi a modell számára, hogy szemantikailag gazdag vizuális reprezentációkat használjon, amelyek rögzítik az objektumstruktúrát, a térbeli kapcsolatokat és a kontextuális információkat.

Radford és munkatársai kimutatták, hogy a CLIP beágyazások erős, átvihető vizuális reprezentációkat biztosítanak több további feladatban, beleértve a képfelismerést és a szemantikai reprezentáció tanulását [14].

## 4.2 Neurális jelek feldolgozása

A neurális modalitás a Neuropixels elektródák segítségével kinyert, túskealapú elektrofiziológiai felvételekből áll. Ezen felvételek feldolgozást Yizi Zhang és munkatársai által bemutatott módszerrel dolgoztam fel, A túskeidőket időbeli cellákba csoportosították úgy, hogy populációs aktivitás reprezentációkat hozzanak létre. Minden időbeli intervallumhoz a túskeszámokat a neuronok között összesíti:

$$x_n \in \mathbb{R}^{D_n}$$

ahol  $x_n$  a neurális jellemzővektort,  $D_n$  a neurális jellemző dimenzióját jelöli [18].

Az így kapott neurális reprezentáció megőrzi az időbeli populációs dinamikát, és csökkenti az érzékenységet a pontos túskeidőzítési zajra.

Egy időbeli konvolúciós kódolót alkalmaztam a már összesített neurális aktivitásra. A neurális kódoló az időbeli jellemzők kinyerését, a lokális mintaaggregációt és a tokengenerálást végzi. A neurális kódoló kimenetét neurális tokenekké alakítja, amelyek időbelileg lokalizált neurális aktivitási mintákat reprezentálnak.

### 4.3 Token generálás

A CLIP vizuális kódoló patch-alapú vizuális reprezentációkat hoz létre. Ezeket a reprezentációkat vizuális tokenekként értelmezi a rendszer:

A vizuális jellemzőket lineárisan képezzük le a transzformátor beágyazási terébe:

$$W_v: D_v \rightarrow D_{model}$$

ahol  $W_v$  a vizuális projekciós mátrix,  $D_v$  a vizuális embedding dimenziója és  $D_{model}$  a transzformátor közös beágyazás terének dimenziója.

Hasonlóképpen, a neurális reprezentációk neurális tokenekké alakítom át külön lineáris leképezéssel képezem le a neurális beágyazásokat a megosztott transzformátortérbe:

$$W_n: D_n \rightarrow D_{model}$$

ahol  $W_n$  a vizuális projekciós mátrix,  $D_n$  a vizuális embedding dimenziója,  $D_{model}$  a transzformátor közös beágyazási terének dimenziója.

A megosztott beágyazási tér lehetővé teszi a vizuális és a neurális reprezentációk közötti közvetlen interakciót a transzformátorfeldolgozás során.

### 4.4 Multimodalitás

A leképezés után a vizuális és neurális tokeneket egyetlen multimodális token szekvenciává fűzöm össze:

$$N = N_v + N_n$$

ahol:  $N$  az összes token száma a multimodális bemenetben,  $N_v$  a vizuális tokenek száma és  $N_n$  a neurális tokenek száma.

Az össze fűzött reprezentáció a tartalmazza a vizuális tokeneket, neurális tokeneket, modalitási beágyazásokat, időbeli pozicionális beágyazásokat és a munkamenet-beágyazásokat.

## 4.5 Beágyazások

Mivel a transzformátorok nem kódolják az időbeli sorrendet, minden egyes token reprezentációhoz tanulható pozicionálási beágyazásokat adok hozzá. A pozicionálási beágyazások megtartják az időbeli struktúrát, és lehetővé teszik a transzformátor számára, hogy modellezze az események közötti szekvenciális összefüggéseket.

Külön modalitás beágyazásokat használok a vizuális és neurális tokenek megkülönböztetésére. Ez lehetővé teszi a transzformátor számára, hogy azonosítsa a tokenek eredetét a keresztmodális figyelmi műveletek során.

A különböző állatokból és kísérleti munkamenetekből származó felvételek eloszlási változékonyságot mutatnak, amelyet okozhatnak az elektróda elhelyezési különbségek, a neuronszám változékonyság, a felvételi zaj vagy a biológiai változékonyság. Ennek a változékonyságnak a kompenzálására munkamenet-specifikus beágyazásokat vezetek be. A munkamenet-beágyazás kontextuális információkat nyújt, amelyek segítik a modellt a munkamenet-függő neurális eloszlásokhoz való alkalmazkodásban.

## 4.6 Transzformátor -alapú szekvencia modellezés

A multimodális token sorozatot egy transzformátor kódoló architektúrával dolgozom fel, amelyet Vaswani és munkatársai [15] által javasolt eredeti transzformátor modellje ihletett.

A transzformátor teljes mértékben az önfigyelő mechanizmusokra támaszkodik a rekurens vagy konvolúciós szekvenciafeldolgozás helyett. A kódoló ismétlődő rétegekből áll, amelyek többfejű önfigyelést, előre csatolt neurális hálózatokat, reziduális kapcsolatokat és réteg normalizálást tartalmaznak. Az önfigyelő művelet kiszámítja az összes token kontextusa közötti kapcsolatokat:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

ahol:

- Q a lekérdezési vektorokat,
- K a kulcsvektorokat,
- V az értékvektorokat,

- $K^T$  a kulcsmátrix transzponáltja,
- $d_k$  a kulcsdimenziót jelöli.

A többfejes figyelmi mechanizmus lehetővé teszi a modell számára, hogy egyszerre több interakciós mintát tanuljon meg.

A transzformátor architektúra képes rögzíteni a hosszú távú időbeli függőségeket, keresztmodális interakciókat, elosztott neurális reprezentációkat és a vizuális és neurális tokenek kontextusa közötti kapcsolatokat.

A transzformátorok skálázhatóságuknak és párhuzamos feldolgozási képességeiknek köszönhetően a modern szekvenciamodellezés és a multimodális tanulási feladatok domináns architektúrájává váltak [15].

## 4.7 Maszkolási stratégia és önfelügyelt tanulás

A rendszer maszkolt modellezési célokat tartalmaz, amelyeket az önfelügyelt transzformátor tanulási megközelítések ihlettek. A betanítás során a vizuális és neurális tokenek részhalmazai véletlenszerűen vannak maszkolva. A modellnek a hiányzó információkat kell rekonstruálnia a maszkolatlan tokenek kontextuális reprezentációinak felhasználásával.

A maszkolási stratégia a következőket tartalmazza a maszkolt vizuális és neurális tokenek predikcióját illetve a keresztmodális maszkolt rekonstrukciót. A maszkolás javítja a reprezentáció robusztusságát, és arra ösztönzi a transzformátort, hogy értelmes látens struktúrát tanuljon meg a közvetlen leképezések memorizálása helyett.

## 4.8 Veszteségfüggvények és optimalizálás

A modellt egy kombinált, többcélú veszteségfüggvénnyel egészítettem ki:

$$L_{total} = \lambda_1 L_{enc} + \lambda_2 L_{dec} + \lambda_3 L_{mask} + \lambda_4 L_{align}$$

ahol:

- $L_{enc}$  a neurális kódolási veszteséget,
- $L_{dec}$  a CLIP dekódolási veszteséget,
- $L_{mask}$  a maszkolt modellezési veszteséget,
- $L_{align}$  az igazítási veszteséget jelenti.

- $\lambda_1, \lambda_2, \lambda_3$ , és  $\lambda_4$  súlyozó együtthatók az egyes veszteség komponensekhez.

A predikció céljától függően az átlagos négyzetes hibát (MSE), a koszinusz hasonlósági veszteséget és az opcionális Poisson negatív logaritmikus valószínűségi veszteségeket használtam. Az optimalizálási folyamatot az Adam optimalizálóval, gradiens alapú visszaterjesztéssel végeztem.

## 4.9 Betanítási stratégia

A modell szinkronizált multimodális adatok felhasználásával, végponttól végpontig tanul be. A betanítás a multimodális token generálás, maszkolt token mintavételezés, transzformátor kódolás, látens predikció, veszteség aggregáció és paraméter optimalizálás lépésekből áll.

A befagyasztott CLIP kódoló csökkenti a számítási igényeket és stabilizálja a betanítást. A batching időbeli ablakokon és rögzítési munkameneteken keresztül történik.

## 5 Kiértékelés

### 5.1 Kiértékelés menete

A rendszert a rekonstrukció pontossága, látens hasonlósági metrikák, koszinusz hasonlóság, neurális predikciós hiba és maszkolt rekonstrukciós teljesítmény alapján értékeltem. Továbbá kiértékeltem, hogy a modell előrejelzése mennyi információt hordoz a tényleges tüzelési aktivitásról. Az értékelés elsődleges célja annak meghatározása, hogy a neurális látens reprezentációk és a CLIP beágyazások milyen pontosan rekonstruálhatók multimodális kontextuális információkból. A tanítást egy munkameneten keresztül végeztem, amely egy adott laboratórium egy egéren végzett több próba felvételét tartalmazta.

A vizuális reprezentációk rekonstrukciós pontosságának meghatározásához a valós és predikált CLIP beágyazási vektorok közötti szögbeli hasonlóságot mérem meg. Az így kapott CLIP koszinusz-hasonlóság metrika az egyhez közeli érték esetén nagy egyezést, míg a nullához közeli érték esetén alacsony hasonlóságot mutat.

A próba szintű  $R^2$  metrika azt méri, hogy a modell mennyire pontosan képes reprodukálni az egyes próbák során megfigyelt neurális aktivitás értékeit. Egyhez közeli  $R^2$  érték esetén a modell jobban, nullához közeli érték esetén a modell nem jobban és negatív érték esetén a modell rosszabbul teljesít mintha az átlagot prediktálná.

Az inger körüli időhisztogram (PSTH), több ismételt próba átlagolásával adja meg a neuronok ingerre adott átlagos időbeli válaszát. A PSTH  $R^2$  metrika annak mérésre szolgál, hogy a modell mennyire képes reprodukálni a neuronok átlagos időbeli válaszát egy adott ingerre. Egyhez közeli  $R^2$  érték esetén a valós és a prediktált PSTH görbe közel megegyezik. Nullához közeli  $R^2$  érték esetén a modell nem írja le jobban az átlagos neurális válaszgörbét, mint annak átlagértéke. Negatív  $R^2$  érték esetén által becsült válaszgörbe rosszabbul közelíti a valós PSTH görbét, mint egy konstans átlagérték.

Tüzelésenkénti bitek (BPS) metrika annak mérésre szolgál, hogy a modell mennyire képes azonosítani azokat az időszakokat, amikor a neuronok aktívabbak vagy kevésbé aktívak. Az egyhez közeli BPS érték jó egyezést, a nulla körüli érték gyenge egyezést, míg a negatív érték rossz egyezést mutat a prediktált és a tényleges tüzelési aktivitás között.

## 6 Eredmények

2. táblázat A modell predikciós teljesítményének eredményei egy munkamenetes kiértékelés során.

|                            |          |
|----------------------------|----------|
| CLIP koszinusz-hasonlóság  | 0.99175  |
| Próba szintű $R^2$         | -0.00389 |
| PSTH $R^2$                 | -0.67825 |
| Tüzelésenkénti bitek (BPS) | -0.01476 |

Az egy munkamenetes betanítási kísérlet vegyes eredményeket hozott. A koszinusz-hasonlósági metrika elérte a körülbelül 0,992-t, ami azt jelzi, hogy a modell képes volt nagy hasonlósággal rekonstruálni a CLIP beágyazási reprezentációkat. Ez arra utal, hogy a javasolt multimodális transzformátor sikeresen megtanult egy erős kapcsolatot a vizuális ingerek és a látens vizuális beágyazási tér között a vizsgált munkameneten belül.

Azonban a további neurális értékelési metrikák azt mutatták, hogy a közvetlen neurális aktivitás predikciójának minősége továbbra is korlátozott maradt. A kapott átlagos  $R^2$  értékek negatívak voltak mind a próbaszintű, mind a PSTH-alapú értékeléseknél. A negatív BPS érték azt jelzi, hogy a modell előrejelzése kevesebb információt hordoz a tényleges tüzelési aktivitásról, mint egy egyszerű átlagos tüzelési rátán alapuló referencia modell. A negatív  $R^2$  értékek azt jelzik, hogy a modell még nem teljesített jobban egy egyszerű alap prediktorral a részletes neurális tüzelési dinamika rekonstrukciójában.

Fontos megjegyezni, hogy ezen eredményeket nagyban befolyásolja, hogy a kiválasztott munkamenet mely régiókban és milyen minőségben rögzített.

## 7 Célkitűzések

Ezen munka folytatásaként a következő feladatokat határoztam meg:

A modell javítása esemény modalitások bevezetésével. Miszerint a modellnek meg kell tanulnia a vizuális inger, neurális adatok és a feladat eseményei közötti kapcsolatot.

A modellnek továbbá meg kell tanulnia és képesnek kell lennie előre jelezni a neurális felvételek klasztereit és az egyes neuronokhoz tartozó agy régiókat.

## Irodalomjegyzék

- [1] Meyer, L. M., Zamani, M., Rokai, J., Demosthenous, A.:  
Deep learning-based spike sorting: a survey, *Journal of Neural Engineering* – IOP Publishing, Vol. 21, 2024, Article 061003
- [2] Gibson, S., Judy, J. W., Marković, D.:  
Spike Sorting: The First Step in Decoding the Brain, *IEEE Signal Processing Magazine* – IEEE, Vol. 29, No. 1, 2012, pp. 124–143
- [3] Adrian, E. D., Zotterman, Y.:  
Action potentials in mammalian nerve fibres, *The Journal of Physiology*, 1952
- [4] Rokai, J., Ulbert, I., Márton, G.:  
Edge computing on TPU for brain implant signal analysis, *Neural Networks* – Elsevier, Vol. 162, 2023, pp. 212–224
- [5] Tsiouris, K. M., Pezoulas, V. C., Zervakis, M., Konitsiotis, S., Koutsouris, D. D., Fotiadis, D. I.:  
A Long Short-Term Memory deep learning network for the prediction of epileptic seizures using EEG signals, *Computers in Biology and Medicine* – Elsevier, Vol. 99, 2018, pp. 24–37
- [6] Zhang, J., Zheng, C., Li, J., et al.:  
A scheme combining feature fusion and hybrid deep learning models for epileptic seizure detection and prediction, *Scientific Reports – Nature Portfolio*, Vol. 14, 2024, Article 16916
- [7] Yan, K., Luo, X., Ye, L., et al.:  
Automated seizure detection in epilepsy using a novel dynamic temporal–spatial graph attention network, *Scientific Reports – Nature Portfolio*, Vol. 15, 2025
- [8] International Brain Laboratory, Angelaki, D., Benson, B., Carandini, M., Harris, K. D., Häusser, M., Hofer, S. B., Svoboda, K., Witten, I. B., et al.:  
A brain-wide map of neural activity during complex behaviour, *Nature* – Nature Publishing Group, Vol. 645, No. 8079, 2025, pp. 177–191,  
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12408349>
- [9] International Brain Laboratory:  
Publicly Available IBL Data – Introduction to the IBL experiments,  
[https://docs.internationalbrainlab.org/public\\_docs/public\\_introduction.html](https://docs.internationalbrainlab.org/public_docs/public_introduction.html)
- [10] International Brain Laboratory; Angelaki, D. E.; Benson, B.; Carandini, M.; Harris, K. D.; Häusser, M.; Hofer, S. B.; O’Keefe, J.; Svoboda, K.; Witten, I. B.; et al.:  
*Brain-wide map of neural activity during complex behaviour*, *Nature* – Nature Publishing Group, Vol. 645, 2025, pp. 177–191

- [11] International Brain Laboratory: Spike sorting visualization platform,  
[https://viz.internationalbrainlab.org/app?spikesorting=ss\\_2024-05-06](https://viz.internationalbrainlab.org/app?spikesorting=ss_2024-05-06) (elérés: 2025. dec.)
- [12] Jia, X., Siegle, J. H., Bennett, C., Gale, S., Denman, D., Koch, C., Olsen, S. R.: Neuropixels 2.0: A miniaturized high-density probe for stable, long-term brain recordings, *Science – American Association for the Advancement of Science*, Vol. 372, No. 6539, 2021,  
<https://www.science.org/doi/10.1126/science.abf4588>
- [13] Buccino, A. P., Hurwitz, C. L., Garcia, S., Magland, J., Siegle, J. H., Hurwitz, R., Hennig, M. H.: SpikeDeeptector: deep-learning-based spike sorting, *Journal of Neuroscience Methods – Elsevier*, Vol. 326, 2019, Article 108327,  
<https://www.sciencedirect.com/science/article/pii/S0165027019301761>
- [14] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., et al.: Learning Transferable Visual Models From Natural Language Supervision, *Proceedings of the 38th International Conference on Machine Learning (ICML)*, Vol. 139, 2021, pp. 8748–8763,  
<https://proceedings.mlr.press/v139/radford21a.html>
- [15] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., Polosukhin, I.: Attention Is All You Need, *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 30, 2017, pp. 5998–6008,  
<https://papers.nips.cc/paper/7181-attention-is-all-you-need>
- [16] Artificial intelligence applications in neuroscience research, *PMC – PubMed Central*, 2025,  
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12036447/>
- [17] Buccino, A. P., Hurwitz, C. L., Garcia, S., Magland, J., Siegle, J. H., Hurwitz, R., Hennig, M. H.: SpikeDeeptector: deep-learning-based spike sorting, *Journal of Neuroscience Methods – Elsevier*, Vol. 326, 2019, Article 108327,  
<https://www.sciencedirect.com/science/article/pii/S0165027019301761>
- [18] Jia, X., Siegle, J. H., Bennett, C., Gale, S., Denman, D., Koch, C., Olsen, S. R.: Neuropixels 2.0: A miniaturized high-density probe for stable, long-term brain recordings, *Science – American Association for the Advancement of Science*, Vol. 372, No. 6539, 2021,  
<https://pmc.ncbi.nlm.nih.gov/articles/PMC8206408/>